

Análisis anomalías en infraestructura ferroviaria.

El siguiente informe, describe las diferentes pruebas realizadas buscando el mejor modelo posible para un autoencoder capaz de detectar anomalías en perfiles de vibraciones captadas por un acelerometro en una simulacion con una maqueta de tren.

El modelo debera ser capaz de forma autonoma, de detectar cuando ciertas vibraciones o inconsistencias en los datos, generan un perfil diferente al esperado por el modelo, pudiendo catalogar la via como "defectuosa".

Jose

Last updated: May 15, 2026

✓ Dataset y spliteo:

Para la realización del ejercicio se han usado datos sintéticos por no disponer todavía del escenario y medios para poder realizar la obtención de datos final. De este modo el proyecto dispone de 3 csv

- train_vibrations_normal.csv
- test_vibrations_normal.csv
- test_vibrations_anomaly.csv

El primero de los cuales representa la simulación de datos que se esperaría obtener de manera realista, y con la que se realiza el entrenamiento por el modelo.

Los archivos test_* corresponden a otros 2 conjuntos de datos sintéticos, creados para efectuar los test. Estos datos por lo tanto son inéditos para el modelo, y con los que se deberá comprobar la eficacia final. De los dos conjuntos de datos de test el primero de ellos tiene un perfil similar al de entrenamiento y se espera que el


modelo lo categorice como correcto si todo funciona como se debe, por otro lado `test_vibrations_anomaly.csv` ha sido modificado intencionadamente para tener picos y alteraciones que destacan sobre los datos de train, y por tanto con una correcta configuración de `threshold`, debiera ser catalogado como anómalo por el modelo.


✓ Experimentación:

Se han realizado aproximadamente unos 10 experimentos principales para comprobar el modelo mas adecuado a el objetivo propuesto, el resumen con los datos principales de estos modelos se encuentra al final del informe.

Lo primero y mas obvio esta en la perdida en relación a las épocas, tanto en entrenamiento como validación. En para esta parte tenemos las dos gráficas siguientes en la que se puede visualizar la situación, aunque a destacar diríamos que:

- Se aprecia claramente la curva de disminución de la perdida, cae rápidamente hasta aproximadamente 20 épocas, gran parte del resultado se ha alcanzado en ese punto, no obstante sigue mejorando de forma paulatina aunque muy minima. Se ha optado por alargar el entrenamiento hasta 100 épocas, porque el modelo entrena en un tiempo razonablemente rápido como para poder ser viable gastar ese tiempo en computo extra por poder mejorar unas centésimas. La excepción fue la run 08 en el que se prueban 150 épocas, considerándose que ya se entra en un punto de estancamiento sin mejora apreciable para lo que es un aumento del 50% del entrenamiento.





Las dosgráficas permiten ver la funcionalidad del entrenamiento y ver que este mejora correctamente y se produce aprendizaje. De eso no hay duda con todas las pruebas realizadas, por lo que a grandes rasgos sabemos que la arquitectura, en todas sus variantes, va ser válida en mayor o menor medida para el propósito del proyecto.


Pero dado que el objetivo es detectar anomalías en la vía del tren, lo cierto es que no puedo considerar esta métrica como la clave para elegir modelo, y optar por aquel que tenga menor pérdida



simplemente.

Por la naturaleza del proyecto, estamos tratando en el fondo de la cuestión, separar correctamente lo que es un perfil de vibraciones normales y esperable, de uno producido por una vía defectuosa. Si el autoencoder que he creado tiene demasiada capacidad y minimiza enormemente la pérdida, pero aun así reconstruir patrones incorrectos, haciéndolo inútil como detector, en especial en estos contextos donde hay asimetría de datos y lo normal es que las vías "correctas" sean superiores a las "incorrectas" un modelo que no mirase eso, se sesgaría diciendo que todo casi siempre está bien, porque estadísticamente es lo que pasa, pero la clave del proyecto es detectar cuando esto no pasa priorizamos por lo tanto:

- En el conjunto normal, no debe activar una alerta global.
- En el conjunto anómalo, sí debe activar una alerta.
- El ratio de ventanas sospechosas en datos normales debe mantenerse bajo.
- El ratio de ventanas sospechosas en datos anómalos debe ser suficientemente alto.
- La separación entre el error medio normal y el error medio anómalo debe ser elevada.

Por este motivo, después de analizar `train/loss` y `val/loss`, se comparan métricas específicas de detección: `test_normal/anomaly_ratio`, `test_anomaly/anomaly_ratio` y `evaluation/separation_score`.





Gracias a esto, se pone el foco en si el modelo genera falsas alarmas, o si por el contrario se le estan escapando anomalias importantes y que es crucial detectar.

Para esto ademas hemos creado la gráfica de evaluación/separation_score con la que sintetizamos todo esto. Esta resume la capacidad real del modelo para distinguir entre vibraciones normales y anómalas.

$$\text{separation_score} = \frac{\text{error medio de reconstrucción en datos anómalos}}{\text{error medio de reconstrucción en datos normales}}$$

Con esto tenido en cuenta `run-03-large-model` es el que da mejores resultados, ya saca el mayor valor de separación entre datos

Así que indica que, aunque otros modelos puedan tener pérdidas de validación similares o incluso ratios de falsas ventanas más bajos, el modelo grande consigue diferenciar mejor el perfil normal de vibraciones frente a las perturbaciones introducidas.

También mas abajo se observa la tabla ordenada por esta métrica, y sus hiperparametros principales como comparacion

[https://wandb.ai/jmaranguren89-upm/train-anomaly-detection/reports/Analisis-anomalias-en-infraestructura-ferroviaria---VmllldzoxNjg4NDMzOA?
accessToken=tfrov4p2oy25903nv7oxqvmzhmgYW9x3jem53oum6zq4ptmw7qko4vs52nusoux1](https://wandb.ai/jmaranguren89-upm/train-anomaly-detection/reports/Analisis-anomalias-en-infraestructura-ferroviaria---VmllldzoxNjg4NDMzOA?accessToken=tfrov4p2oy25903nv7oxqvmzhmgYW9x3jem53oum6zq4ptmw7qko4vs52nusoux1)

Made with Weights & Biases. [Sign up](#) or [log in](#) to create reports like this one.